МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное бюджетное образовательное учреждение
высшего образования
**«Сибирский государственный университет науки и технологий
имени академика М.Ф. Решетнева»**

Институт информатики и телекоммуникаций

Кафедра информатики и вычислительной техники

ОТЧЕТ ПО ЛАБОРАТОРНОЙ РАБОТЕ

Теория информации

Энтропия как мера степени неопределенности системы

Руководитель _____ А.Н. Бочаров
подпись, дата инициалы, фамилия

Обучающийся БПИ24-02, 24151430 _____ В.Т. Гордов
номер группы, зачетной книжки подпись, дата инициалы, фамилия

Красноярск 2025 г.

ЦЕЛЬ РАБОТЫ

Закрепить теоретические знания и получить практические навыки при вычислении энтропии.

ЗАДАНИЯ

1. Получить таблицу значений функции $\eta(p) = - p * log_2 p$ при изменении p от 0,01 до 0,99 с шагом 0,01.

2. Система может находиться в двух состояниях. Вероятность одного состояния p. Определить значения энтропии при изменении p от 0,01 до 0,99 с шагом 0,01. Определить максимальное значение энтропии. Построить график.

3. Пользуясь таблицей частот русского языка (таб. 2) определить энтропию однобуквенного сочетания русского текста.

Буква	Вероятность	Буква	Вероятность	Буква	Вероятность	Буква	Вероятность
Пробел	0,175	р	0,040	я	0,018	х	0,009
о	0,090	в	0,038	ы	0,016	ж	0,007
е	0,072	л	0,035	з	0,016	ю	0,006
а	0,062	к	0,028	ъ	0,014	ш	0,006
и	0,062	м	0,026	б	0,014	ц	0,004
н	0,053	д	0,025	г	0,013	щ	0,003
т	0,053	п	0,023	ч	0,012	э	0,003
с	0,045	у	0,021	й	0,010	ф	0,001

4. На основе заданного текстового файла определить частоту появления символов в тексте. Определить энтропию однобуквенного сочетания заданного текста.

Примечание. При выполнении четвертого задания исходный текст составляет не менее двух печатных страниц.

Вероятность появления, например, символа А в тексте вычисляется следующим образом:

$$p(\text{A}) = m/n ,$$

где m – число появлений символа А; n – общее число символов в тексте.

Вариант 5

каменного здания, мимо которого мы проходим.
Оборудование... слишком незнакомое, чтобы можно было его опознать. Несколько
человек за столами. У одного в руках пробирка. Ха, химические опыты в
виртуальном пространстве! Что-то новое. Имеет смысл, лишь если работа ведется
над очень ядовитыми веществами... или с бактериальными средами. Возьмем на заметку.
- Куда вы меня ведете? - интересуюсь у охранника. Лысина не оборачивается, но отвечает:
- К директору корпорации.
Имени он не называет, но и без того сказано многое. "Аль-Кабар" -

транснациональная корпорация, специализирующаяся на производстве лекарств, телефонной связи, кажется - еще на добыче нефти... Несмотря на весь арабский антураж, контролируется она из Швейцарии. Директор ее, Фридрих Урман - личность
слишком значительная, чтобы беседовать с каждым посетителем.
Теплая готовится встреча.
Мы останавливаемся у маленькой, увитой виноградом деревянной беседки, сзади меня
подталкивают, и я вхожу. Охранники остаются за порогом.
Внутри помещение куда больше, чем снаружи. Огромный павильон, в центре бассейн,
где медленно плавают сонные, блестящие рыбы. Рядом столик с двумя креслами.
Очень много цветов, я даже начинаю чувствовать запахи.
И никого.
Что ж... подождем. Сажусь в кресло.
Легкая муть перед глазами... что и следовало ожидать. Сейчас прощупывают мой канал связи. Пытаются определить, откуда я пришел, объем информации, которую
могу принимать и передавать за секунду, присутствующие при мне программы...
Давайте, работайте. Шесть арендованных "на раз" роутеров, через которые пробегает сигнал. И все достаточно стойкие к взлому. А под конец - платный интернетовский гейт в Австрии, через который я и вошел в виртуальность.
Следы останутся, но никуда не приведут.
Можно в любой момент оборвать связь, "вышвырнуть" меня из квартала. Только что
им это даст... все вещички-программки, что находятся при мне, немедленно сработают. Мало что останется для изучения. А я им очень интересен, сомнений нет...
- Отслежен первый роутер, - сообщает "Виндоус-Хоум".
Быстро. Качаю головой - и в этот момент кресло напротив перестает быть пустым.
Господин Фридрих Урман пренебрегает арабским колоритом. Он в шортах, цветастой
рубашке. Пожилой, сухопарый, серьезный.
- Добрый день... дайвер, - произносит он. По-русски. Голос неестественный, пропущенный через программу-переводчик.
Вот и причина столь высокой чести.
- Боюсь, что вы ошибаетесь, господин директор.
- Когда полгода назад мы создали мост, это преследовало лишь одну цель, господин
дайвер. Обнаружить вас. Человек, находящийся в виртуальности, не смог бы его преодолеть, - Урман скупо улыбается. - Я первый раз вижу настоящего дайвера.
Один-ноль... не в мою пользу.

- А я первый раз вижу настоящего мультимиллионера.
- Вот видите, наша встреча уже принесла первые плоды.
"Виндоус-Хоум" шепчет:
- Отслежен второй роутер.
Урман хмурится - похоже, и ему что-то сообщают. Потом интересуется:
- Простите, через сколько компьютеров вы прошли на пути сюда?
- К сожалению, я не помню.
Урман пожимает плечами.
- Как я могу вас называть?
- Иван-Царевич.
Секундная пауза - потом улыбка. Ему объяснили.
- О, русский сказочный герой! А вы сами - русский?
- Разве это имеет значение?
- Да, вы совершенно правы... Господин дайвер, как я понимаю, вы проникли в наш
квартал незаконно...
- Разве? - поражаюсь я. - Честно говоря, просто искал работу. Прочитал ваше объявление, прошел по мосту... подчинился этим странноватым охранникам. Один-один.
Фридрих Урман всплескивает руками.
- Да... действительно! Но у нас и нет претензий в ваш адрес, господин дайвер. Разве что странные вещи, которые вы носите с собой...
Медленно, демонстративно, вытаскиваю все из карманов. Расческа, носовой платок,
маленькое зеркальце.
- Вот. Отдать вам меч?
Урман машет руками:
- Господи, к чему? Мы же не собираемся устраивать потасовок, верно? Давайте поговорим...
- Отслежен третий роутер.
- Как жаль, что времени на беседу остается все меньше и меньше, - вздыхаю я.
- Да, но времени всегда не хватает. Итак, господин дайвер, у меня есть основания полагать, что некоторые лица хотели бы получить ряд наших разработок. И даже ухитрились нанять дайвера... чтобы пожать чужие плоды.
- Яблочки, - уточняю я.
- Да, именно. У нас работает хороший русский программист, он сделал красивую форму для хранения информации... - Урман хлопает в ладоши, и рядом с нами воздух
начинает мутнеть, сгущаться. Миг - и возникает маленькое деревце, усыпанное плодами. - Полагаю, что наибольший интерес вызывает вон то, маленькое зеленое
яблочко на нижней ветке.
Я смотрю на вожделенный плод. Он мелкий, незрелый и червивый.

- Как вы думаете, дайвер, сколько могли бы заплатить наши конкуренты за этот файл?
- Тысяч десять, - несколько завышаю цену.
Урман недоуменно смотрит на меня. Уточняет:
- Десять тысяч долларов?
- Да.
- Честно говоря, даже сто тысяч были бы невысокой наградой... Хорошо. Допустим,
я предлагаю человеку, пытавшемуся украсть файл, сто пятьдесят тысяч. При условии, что он начнет сотрудничать с нами... за нормальную, хорошую плату.
- Это что, лекарство от рака? - спрашиваю я.
Урман качает головой:
- Нет. Тогда бы оно не имело цены. Это лишь средство от простуды, но очень, очень действенное. Мы готовимся начать его производство, но лишь после того, как
будут распроданы запасы менее действенных лекарств. Так что вы скажете о моем
предложении?

ХОД РАБОТЫ

Задание 1

Рассчитываем значение *η(p)* по формуле для каждого *p* (Таблица 1).

Таблица 1 — Задание 1

p	η (p)
0,01	0,066439
0,02	0,112877
0,03	0,151767
0,04	0,185754
0,05	0,216096
0,06	0,243534
0,07	0,268555
0,08	0,291508
0,09	0,312654
0,10	0,332193
0,11	0,350287
0,12	0,367067
0,13	0,382644
0,14	0,39711
0,15	0,410545
0,16	0,423017
0,17	0,434587
0,18	0,445308
0,19	0,455226
0,20	0,464386
0,21	0,472823
0,22	0,480573
0,23	0,487668
0,24	0,494134
0,25	0,5
0,26	0,505288
0,27	0,510022
0,28	0,51422
0,29	0,517904
0,30	0,52109
0,31	0,523795
0,32	0,526034

Выводы

В ходе выполнения задания была получена таблица значений вспомогательной функции *η(p)*. Значения показывают вклад каждого отдельного состояния в суммарную энтропию системы. Нелинейность функции подтверждает необходимость использования логарифмических вычислений для оценки количества информации и энтропии.

Задание 2

Рассчитываем значение энтропии системы *H(p)* по формуле Шеннона, после чего находим максимальное возможное значение для системы (Таблица 2) и отражаем полученные данные на графике (Рисунок 1).

Таблица 2 — Задание 2

Вероятность p	Энтропия H (бит/сим)
0,01	0,081
0,02	0,141
0,03	0,194
0,04	0,242
0,05	0,286
0,06	0,327
0,07	0,366
0,08	0,402
0,09	0,436
0,10	0,469
0,11	0,500
0,12	0,529
0,13	0,557
0,14	0,584
0,15	0,610
0,16	0,634
0,17	0,658
0,18	0,680
0,19	0,701
0,20	0,722
0,21	0,741
0,22	0,760
0,23	0,778
0,24	0,795
0,25	0,811
0,26	0,827
0,27	0,841
0,28	0,855
0,29	0,869
0,30	0,881
0,31	0,893
0,32	0,904

Макс. H (бит/сим)
1,000

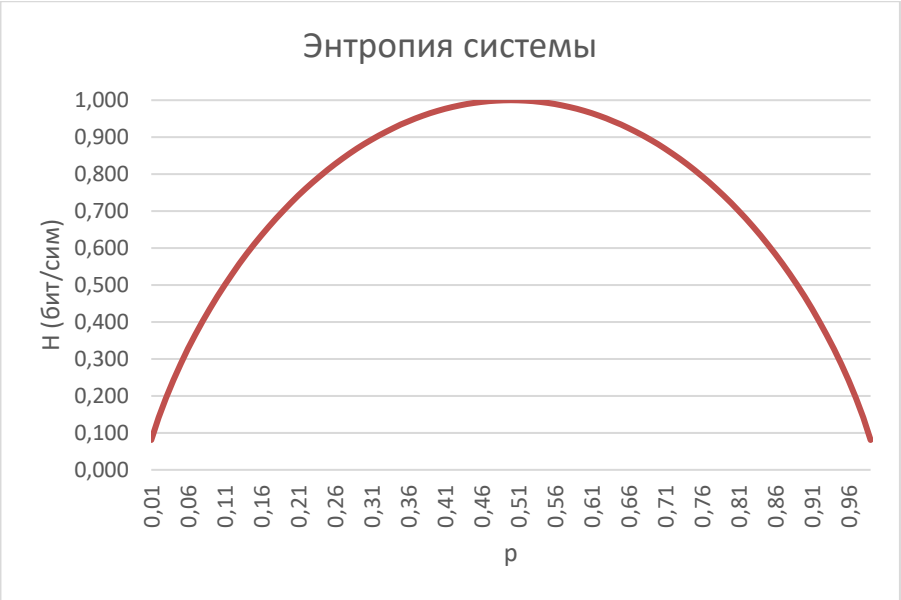

Рисунок 1 — График энтропии системы

Выводы

В ходе выполнения задания были получены значения энтропии для каждого случая (набора вероятностей), а также общей энтропии системы. Полученные результаты подтверждают фундаментальное свойство энтропии: она достигает своего максимума при наибольшей неопределённости, т.е. при равновероятности всех возможных исходов.

Задание 3

Вычисляем значение энтропии *H(p)* для каждой буквы, после чего суммируем полученные значения и получаем значение энтропии *H* системы (Таблица 3).

Таблица 3 — Задание 3

Буква	Вероятность		H буквы (бит/сим)		
Пробел	0,175		0,440050305		
о	0,09		0,312653807		
е	0,072		0,273301868		
а	0,062		0,248718454		
и	0,062		0,248718454		
н	0,053		0,224606783		
т	0,053		0,224606783		H системы (бит/сим)
с	0,045		0,201326903		4,349
р	0,04		0,185754248		
в	0,038		0,179278557		
л	0,035		0,169277544		
к	0,028		0,144436022		
м	0,026		0,136898959		
д	0,025		0,133048202		
п	0,023		0,125171114		
у	0,021		0,117042804		
я	0,018		0,104325467		
ы	0,016		0,095452549		
з	0,016		0,095452549		
ъ/ь	0,014		0,086218011		
б	0,014		0,086218011		
г	0,013		0,081449479		
ч	0,012		0,076569861		
й	0,01		0,066438562		
х	0,009		0,061162734		
ж	0,007		0,050109006		
ю	0,006		0,044284931		
ш	0,006		0,044284931		
ц	0,004		0,031863137		
щ	0,003		0,025142465		
э	0,003		0,025142465		

Выводы

В ходе выполнения задания было рассчитано значение энтропии однобуквенного выражения для данного 32-буквенного алфавита, равно 4,349 бит/символ. Это значение меньше максимально возможного в 5 бит/сим, что объясняется неравномерностью распределения частот букв в языке.

Задание 4

Для выполнения задания было создано консольное приложение, написанное на языке Python. Исходный код программы представлен ниже.

Файл **header.py**

```
import math
from collections import Counter

class TextEntropyAnalyzer:
    """Анализатор энтропии текста.
    """
    def __init__(self):
        self._filepath = "" # Файл с текстом
        self._text = "" # Текст для обработки

        self._char_counts = Counter() # Количество каждого символа
        self._letters_probabilities = {} # Вероятность каждого символа

        self._total_chars = 0 # Общее количество символов
        self._entropy = 0.0 # Энтропия системы

        self._is_analyzed = False # Флаг состояния

    def load_file(self, filepath):
        """Считывает текст из файла.

        Args:
            filepath (string): Название файла

        Returns:
            bool: Результат загрузки
        """
        try:
            with open(filepath, 'r', encoding='utf-8') as file:
                self._text = file.read()

            self._filepath = filepath
            self._is_analyzed = False
            return True
        except FileNotFoundError:
            raise FileNotFoundError(f"Файл '{filepath}' не найден.")
        except Exception as e:
            raise IOError(f"Ошибка при чтении файла: {e}") from e

    def analyze(self):
        """
```

```
        Анализирует загруженный текст, высчитывая энтропию текста,
        вероятность каждого символа и их общее количество.

        Returns:
            bool: Результат анализа
        """
        if not self._text:
            raise ValueError("Входной текст пуст или файл не загружен.")

        # Обработка текста
        clear_text = self._text.lower()
        self._total_chars = len(clear_text)
        self._char_counts = Counter(clear_text)
        self._letters_probabilities = {}

        # Рассчёт энтропии
        entropy_sum = 0.0 # Суммарная энтропия
        for char, count in self._char_counts.items():
            p = count / self._total_chars # Вероятность символа
            self._letters_probabilities[char] = p

            entropy_sum += -(p * math.log2(p)) # += Энтропия символа

        self._entropy = entropy_sum
        self._is_analyzed = True
        return True

    def print_probability_table(self, limit=None):
        """Форматированный вывод таблицы вероятностей в консоль.

        Args:
            limit (int, опционально): Количество строк для вывода. None — все
строки.
        """

        if not self._is_analyzed:
            raise RuntimeError("Текст ещё не проанализирован!")

        # Сортировка: по убыванию вероятности (-item[1]), затем по алфавиту
(item[0])
        sorted_items = sorted(self._letters_probabilities.items(), key=lambda item:
(-item[1], item[0]))

        # Если задан лимит, обрезаем список
        if limit is not None:
            data_to_print = sorted_items[:limit]
            title = f"ТОП-{limit} СИМВОЛОВ"
        else:
            data_to_print = sorted_items
```

```
            title = "ПОЛНАЯ ТАБЛИЦА ВЕРОЯТНОСТЕЙ"

        print("\n" + "=" * 50)
        print(f"{title:^50}")
        print("=" * 50)
        print(f"{'Символ':<10} | {'Кол-во':<10} | {'Вероятность':<15}")
        print("-" * 50)

        for char, prob in data_to_print:
            count = self._char_counts[char]
            print(f"{repr(char):<10} | {count:<10} | {prob:.6f}") # repr() нужен
для отображения спецсимволов (\n, \t)

        print("-" * 50)

    def print_report(self):
        """Выводит краткий отчёт по результатам анализа.
        """

        if not self._is_analyzed:
            print("ОШИБКА: Текст ещё не проанализирован!")
            return

        print("\n" + "="*50)
        print(f"ОТЧЕТ ПО ФАЙЛУ: {self._filepath}")
        print("="*50)
        print(f"Всего символов:      {self._total_chars}")
        print(f"Уникальных символов: {len(self._char_counts)}")
        print(f"ЭНТРОПИЯ ТЕКСТА:     {self._entropy:.4f} бит/символ")
        # Выводим 10 самых частых символов для наглядности.
        self.print_probability_table(limit=10)
```

Файл **main.py**

```
from header import TextEntropyAnalyzer

def main():
    analyzer = TextEntropyAnalyzer()

    while True:
        print("\n--- МЕНЮ ---")
        print("1. Загрузить файл")
        print("2. Проанализировать файл")
        print("3. Результаты анализа")
        print("4. Таблица вероятностей")
        print("0. Выход")

        choice = input("Ваш выбор: ")
```

```
        if choice == "1":
            filename = input("Введите название файла для анализа (Enter — 'in-
put.txt'): ").strip() or "input.txt"
            if(analyzer.load_file(filename)):
                print(f"Файл {filename} был успешно загружен.")
        elif choice == "2":
            if(analyzer.analyze()):
                print("Анализ файла завершён.")
        elif choice == "3":
            analyzer.print_report()
        elif choice == "4":
            analyzer.print_probability_table(None)
        elif choice == "0":
            print("Выход из программы.")
            break
        else:
            print("Неверный ввод.")

if __name__ == "__main__":
    main()
```

В коде представленной программы был реализован класс **TextEntropyAnalyzer**, предназначенный для анализа энтропии текста. Взаимодействие с функциональными методами происходит с помощью консольного меню по следующему алгоритму:

1. Пользователь выбирает желаемый файл;
2. Программа считывает содержимое файла и сохраняет в специальном поле класса;
3. Пользователь запускает функцию анализа текста, в результате чего для каждого символа в тексте вычисляется общее количество его инстанций и вероятность его появления, а для текста в целом вычисляется значение суммарной энтропии системы;
4. Пользователь запрашивает отчёт по результатам анализа, в результате чего в консоль выводится полученная информация.

```
--- МЕНЮ ---
1. Загрузить файл
2. Проанализировать файл
3. Результаты анализа
4. Таблица вероятностей
0. Выход
Ваш выбор:
```

Рисунок 2 — Меню программы

```
Ваш выбор: 1
Введите название файла для анализа (Enter – 'input.txt'): input.txt
Файл input.txt был успешно загружен.
```

Рисунок 3 — Загрузка файла

```
Ваш выбор: 2
Анализ файла завершён.
```

Рисунок 4 — Анализ файла

```
Ваш выбор: 3

==================================================
ОТЧЕТ ПО ФАЙЛУ: input.txt
==================================================
Всего символов:      5370
Уникальных символов: 41
ЭНТРОПИЯ ТЕКСТА:     4.6401 бит/символ

==================================================
                ТОП-10 СИМВОЛОВ
==================================================
Символ     | Кол-во     | Вероятность
--------------------------------------------------
' '        | 735        | 0.136872
'о'        | 445        | 0.082868
'е'        | 374        | 0.069646
'а'        | 345        | 0.064246
'т'        | 289        | 0.053818
'н'        | 285        | 0.053073
'и'        | 256        | 0.047672
'р'        | 232        | 0.043203
'с'        | 225        | 0.041899
'в'        | 183        | 0.034078
--------------------------------------------------
```

Рисунок 5 — Отчёт по результатам анализа

```
Ваш выбор: 4

==================================================
            ПОЛНАЯ ТАБЛИЦА ВЕРОЯТНОСТЕЙ
==================================================
Символ      | Кол-во      | Вероятность
--------------------------------------------------
' '         | 735         | 0.136872
'о'         | 445         | 0.082868
'е'         | 374         | 0.069646
'а'         | 345         | 0.064246
'т'         | 289         | 0.053818
'н'         | 285         | 0.053073
'и'         | 256         | 0.047672
'р'         | 232         | 0.043203
'с'         | 225         | 0.041899
'в'         | 183         | 0.034078
'м'         | 154         | 0.028678
'.'         | 149         | 0.027747
'л'         | 144         | 0.026816
'д'         | 133         | 0.024767
'к'         | 127         | 0.023650
'у'         | 120         | 0.022346
'п'         | 116         | 0.021601
'\n'        | 98          | 0.018250
','         | 92          | 0.017132
'ы'         | 92          | 0.017132
'я'         | 88          | 0.016387
'ь'         | 84          | 0.015642
'ч'         | 77          | 0.014339
'й'         | 66          | 0.012291
'-'         | 65          | 0.012104
'з'         | 60          | 0.011173
'г'         | 57          | 0.010615
'б'         | 56          | 0.010428
'ш'         | 36          | 0.006704
'ж'         | 34          | 0.006331
'х'         | 33          | 0.006145
'ю'         | 33          | 0.006145
'ц'         | 18          | 0.003352
'щ'         | 16          | 0.002980
'?'         | 13          | 0.002421
'"'         | 10          | 0.001862
'ф'         | 10          | 0.001862
'э'         | 8           | 0.001490
':'         | 6           | 0.001117
'!'         | 3           | 0.000559
'ъ'         | 3           | 0.000559
--------------------------------------------------
```

Рисунок 6 — Таблица вероятностей символов

Выводы

Полученные по результатам работы программы (Рисунки 2-6) значения близки к теоретическим. Так, экспериментально полученное значение энтропии системы в 4,6401 бит/сим незначительно превышает теоретическое значение в 4,35 бит/сим, что объясняется фактом учёта не только 32 букв алфавита, но также и других символов (регистровые, знаки препинания и т.д.), что увеличило общий алфавит системы и сопутствующую неопределённость (энтропию).

ОТВЕТЫ НА КОНТРОЛЬНЫЕ ВОПРОСЫ

1. **Что такое энтропия и каковы ее свойства?**
   Энтропия — это мера неопределённости системы, которая показывает, насколько случайным является выбор того или иного состояния системы.
   Свойства:
   - Положительность: не меньше нуля;
   - Обращение в ноль: равна нулю, если одно из состояний достоверно;
   - Максимальность: в случае равновероятности всех исходов;
   - Аддитивность: общая энтропия системы объединённых независимых систем равна сумме энтропий каждой системы.
2. **Как вычисляется энтропия системы?**
   Формула Шеннона: $H(X) = -\sum_{i=1}^{n} p_i * \log_2 p_i$
3. **От каких параметров системы зависит энтропия системы?**
   Число состояний и распределение вероятностей состояний.
4. **В каких единицах может измеряться энтропия системы?**
   «Бит» для логарифма с основанием 2, «Нат» для натурального и «Дит» для десятичного.
5. **Как определяется один бит информации в теории информации?**
   Один бит это энтропия простейшей системы, имеющей два равновероятных варианта.
6. **Как вычисляется максимальная энтропия?**
   Энтропия максимальна при равновероятности состояний системы. Тогда формула Шеннона упрощается до формулы Хартли:
   $H_{max} = \log_2 n$
7. **Как определяется энтропия через математическое ожидание?**
   Энтропию можно представить как математическое ожидание (среднее значение) логарифма вероятности состояния системы, взятое с обратный знаком. Случайная величина здесь — это $\log P(X)$.
   Формула через матожидание: $H(X) = M[-\log P(X)]$
   Это означает, что энтропия есть среднее значение «неожиданности» событий.

ВЫВОДЫ

В ходе выполнения лабораторной работы были закреплены теоретические знания и понятии энтропии как меры неопределённости системы. Были получены практические навыки вычисления энтропии вручную и с использованием программных средств.

Исходя из полученных результатов вычисления, можно сделать вывод о том, что мера энтропии зависит как от размеры используемого алфавита, так и от частоты появления каждого отдельного символа данного алфавита.