2.7.1 Количественное определение избыточности

Пусть передается сообщение из n взаимозависимых и неравновероятных элементов. Количество информации, передаваемое данным сообщением равняется:

$$I = n \cdot I' ,$$

где I' - количество информации, приходящейся на один символ.

Если устранить все внутренние вероятностные связи, то информация, передаваемая одним символом, возрастет до максимального значения $I'_{\max}$. При этом тоже количество информации может содержаться в сообщении из меньшего числа элементов n_0. Тогда

$$I = n \cdot I' = n_0 I'_{\max} .$$

Таким образом, мерой избыточности может быть принято относительное число лишних элементов в сообщении

$$D = \frac{n - n_0}{n} = 1 - \frac{n_0}{n} . \qquad (56)$$

Если рассматривать определение избыточности с точки зрения передачи информации, то когда энтропия передаваемого сообщения не равна максимальной (максимальная энтропия определяется для алфавита с определенным количеством качественных признаков), сообщение является недогруженным, то есть данное сообщение может нести большее количество информации.

Абсолютная недогруженность на символ сообщений такого источника определяется как

$$\Delta D = (H_{\max} - H) \quad бит/символ .$$

На практике для определения избыточности используют следующее выражение

$$D = \frac{H_{\max} - H}{H_{\max}} = 1 - \frac{H}{H_{\max}} , \qquad (57)$$

где H и H_{max} берутся относительно одного и того же алфавита.

Исходя из выражения (57) избыточность показывает относительную недогруженность на символ сообщения.

Кроме общего понятия избыточности существуют частные виды избыточности.

1. Избыточность, обусловленная неравновероятным распределением символов в сообщении:

$$D_p = 1 - \left(\frac{-\sum_i p_i \log_2 p_i}{\log_2 m} \right), \qquad (58)$$

где m – количество символов алфавита.

2. Избыточность, вызванная статистической связью между символами сообщения:

$$D_s = 1 - \frac{-\sum_{i=1}^{n} \sum_{j=1}^{m} p_i p(y_j | x_i) \log_2 p(y_j | x_i)}{-\sum_i p_i \log_2 p_i} . \qquad (59)$$

Полная информационная избыточность определяется следующим образом:

$$D = D_s + D_p - D_s D_p . \qquad (60)$$

2.7.2 Оптимальное неравномерное кодирование

Основная идея построения оптимальных неравномерных кодов заключается в следующем: символы в сообщении появляются с различной вероятностью, поэтому редко встречающиеся символы кодируются длинной кодовой последовательностью, часто встречающиеся – короткой.

Данная идея лежит в основе алгоритмов кодирования Шеннона-Фано и Хаффмана.

Алгоритм Шеннона-Фано.

Согласно методике Шеннона-Фано построение оптимального неравномерного кода сводится к следующему:

1. Алфавит из n букв (или комбинации букв) располагается в порядке убывания вероятностей их появления в сообщениях.

2. Первоначальный алфавит кодируемых символов (сообщений) разбивается на две группы таким образом, чтобы суммарные вероятности сообщений обеих групп были по возможности равны. Если равной вероятности в подгруппах нельзя достичь, то их делят так, чтобы разница между вероятностями в делимых подгруппах была минимальна.

3. Первой группе присваивается символ 1**,** второй группе - символ 0.

4. Каждую из образованных подгрупп делят на две части таким образом, чтобы суммарные вероятности вновь образованных подгрупп были по возможности равны.

5. Первым группам каждой из подгрупп вновь присваивается 1, а вторым - 0. Таким образом, получается второй символ кода. Затем каждая из полученных

групп вновь делится на равные (с точки зрения суммарной вероятности) части до тех пор, пока в каждой из подгрупп не останется по одной букве.

Пример: Построить код Шеннона-Фано для алфавита состоящего из шести букв. Вероятности появления символов следующие:

A	a_1	a_2	a_3	a_4	a_5	a_6
p_i	0,25	0,25	0,25	0,1	0,1	0,05

Решение.

		1	2	3	4
a_1	0,25	1	1		
a_2	0,25	1	0		
a_3	0,25	0	1		
a_4	0,1	0	0	1	
a_5	0,1	0	0	0	1
a_6	0,05	0	0	0	0

Алгоритм Хаффмана

Методика построения кода следующая.

Пусть имеется алфавит А, содержащий буквы a_1, a_2, ... a_n, вероятности появления которых p_1, p_2, ... p_n.

1. Расположим буквы в порядке убывания их вероятностей.

2. Две буквы алфавита А, объединяем в новую букву (в случае кодирования двоичным алфавитом). Вероятность новой буквы равна сумме вероятностей объединяемых букв из алфавита А. Получаем новый алфавит A_1.

3. Буквы алфавита A_1 также располагаем в порядке убывания их вероятностей.

4. Две последние буквы алфавита A_1 объединяются в новую букву. Получаем алфавит A_2. Процедура сжатия (образование новых алфавитов) продолжается до тех пор, пока в последнем алфавите не останется две буквы.

Кодирование:

1. Две буквы последнего алфавита кодируются нулем и единицей.

2. Затем кодируется предыдущий алфавит. При этом буквы алфавита имеют те же кодовые комбинации, а к коду двух последних букв добавляется ноль или единица.

Пример: Закодировать методом Хаффмана алфавит из шести букв. Вероятности появления букв даны.

A	a_1	a_2	a_3	a_4	a_5	a_6
p_i	0,4	0,2	0,2	0,1	0,05	0,05

Решение.

Сжатие алфавита:

		A_1	A_2	A_3	A_4
a_1	0,4	0,4	0,4	0,4	0,6
a_2	0,2	0,2	0,2	0,4	0,4
a_3	0,2	0,2	0,2	0,2	
a_4	0,1	0,1	0,2		
a_5	0,05	0,1			
a_6	0,05				

Кодирование:

		A_1	A_2	A_3	A_4
a_1	0,4 [0]	0,4 [0]	0,4 [0]	0,4 [0]	0,6 [1]
a_2	0,2 [10]	0,2 [10]	0,2 [10]	0,4 [11]	0,4 [0]
a_3	0,2 [111]	0,2 [111]	0,2 [111]	0,2 [10]	
a_4	0,1 [1101]	0,1 [1101]	0,2 [110]		
a_5	0,05 [11001]	0,1 [1100]			
a_6	0,05[11000]				

Кодирование методом Хаффмана с помощью кодового дерева

На практике зачастую не производят многократного выписывания вероятностей символов с учетом вероятности вновь образованного символа, а обходятся элементарными геометрическими построениями, суть которых сводиться к тому, что символы кодируемого алфавита попарно объединяются в новые символы, начиная с символов, имеющих наименьшую вероятность. Затем с учетом вновь образованных символов, которым присваивается значение суммарной вероятности двух предыдущих, строят кодовое дерево, в вершине которого стоит символ с вероятностью 1. Ветвям дерева присваиваются значения 1 или 0. Код символа определяется движением по ветвям к корню дерева. Ветка исходящая из корня является старшим разрядом. При этом отпадает необходимость в упорядочивании символов кодируемого алфавита в порядке убывания вероятностей.

Пример: Дан алфавит из восьми символов. Построить код Хаффмана.

Решение.

[1]	a_1	0,5
[001]	a_2	0,15
[011]	a_3	0,12
[010]	a_4	0,1
[00011]	a_5	0,04
[00010]	a_6	0,04
[00001]	a_7	0,03
[00000]	a_8	0,02

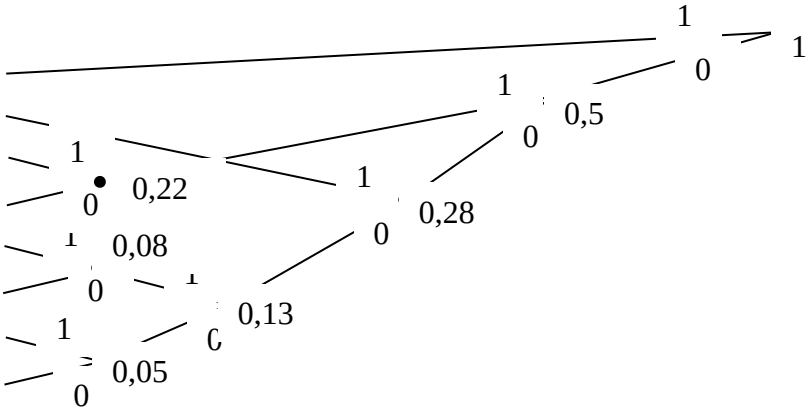

Метод Хаффмана с использованием алфавита из *m* символов

Используя методику Хаффмана можно строить оптимальные коды, если для кодирования используется алфавит из m символов. При построении таких кодов используется процедура сжатия, при которой каждый раз объединяются m букв первичного алфавита. Последовательность сжатия приводит к алфавиту из m букв. Число букв первичного алфавита n должно удовлетворять следующему выражению

$$n = m + k(m-1), \qquad (61)$$

где k – целое число.

Это условие всегда можно достичь, если ввести в исходный алфавит фиктивные буквы, вероятность которых равно нулю.

Пример: Дан алфавит из шести букв. Построить троичный код Хаффмана на основе алфавита, содержащего следующие символы [0, 1, 2].

A	a_1	a_2	a_3	a_4	a_5	a_6
p_i	0,4	0,2	0,2	0,1	0,05	0,05

Решение.

Число символов вторичного алфавита $m = 3$.

Вычисляем выражение (61):

при $k = 1$ $n = 5$;

при $k = 2$ $n = 7$.

Из вычислений видно, что первичный алфавит из шести букв не подходит для кодирования троичным алфавитом. Поэтому к исходному алфавиту добавляем фиктивный символ a_7, вероятность которого равно нулю.

Сжатие:

		A_1	A_2
a_1	0,4	0,4	0,4
a_2	0,2	0,2	0,4
a_3	0,2	0,2	0,2
a_4	0,1	0,1	
a_5	0,05	0,1	
a_6	0,05		
a_7	0		

Кодирование:

		A_1	A_2
a_1	0,4 [0]	0,4 [0]	0,4 [0]
a_2	0,2 [2]	0,2 [2]	0,4 [1]
a_3	0,2 [10]	0,2 [10]	0,2 [2]
a_4	0,1 [11]	0,1 [11]	

a_5	0,05 [120]	0,1 [12]	
a_6	0,05 [121]		
a_7	0 [122]		

Процедура декодирования кодов Шеннона-Фано и Хаффмена является однозначной.

2.7.3 Определение оптимальности закодированных сообщений

Оптимальность полученного кода можно определить по следующим параметрам:

1. Средняя длина кода

$$l_{cp}=\sum_{i=1}^{n} p_i l_i \ , \qquad (62)$$

где p_i – вероятность появления символа первичного алфавита; l_i – длина кодовой комбинации отдельного символа.

При этом должно выполняться соотношение

$$l_{cp}\geq\frac{H}{\log_2 m} \ , \qquad (63)$$

где m – число символов вторичного алфавита; H – энтропия исходного алфавита.

Если используется двоичный алфавит выражение сводится к виду $l_{\text{ср}}\geq H$.

3. Коэффициент статистического сжатия

$$K_{cc}=\frac{H_{\max}}{l_{cp}}=\frac{\log_2 N}{\log_2 m\sum_{i=1}^{N} p_i l_i} \ , \qquad (64)$$

где N – число символов первичного алфавита.

Коэффициент статистического сжатия характеризует уменьшение количества двоичных знаков на символ сообщения при применении оптимального неравномерного кода по сравнению с применением методов нестатического кодирования.

4. Коэффициент относительной эффективности

$$K_{оэ}=\frac{H}{l_{cp}}=\frac{-\sum_{i=1}^{N} p_i \log_2 p_i}{\log_2 m\sum_{i=1}^{N} p_i l_i} \ . \qquad (65)$$

Коэффициент относительной эффективности показывает насколько используется статистическая избыточность передаваемого сообщения.